


SVD. Eigenfaces. PCA. Линейные системы

Даня Меркулов

МФТИ. AI360

Сингулярное разложение матрицы

Сингулярное разложение матрицы



Для любой матрицы $A \in \mathbb{R}^{m \times n}$ существует разложение:

$$A = U\Sigma V^*,$$

где

- $U \in \mathbb{R}^{m \times m}$ - унитарная матрица левых сингулярных векторов

u, sigma, vt = ~~np.linalg.svd(A)~~

Сингулярное разложение матрицы

 $A_{m \times n}$

=

 $U_{m \times m}$ σ_1
 σ_2
 σ_3
...
 σ_r $\Sigma_{m \times n}$ $V_{n \times n}^*$

Для любой матрицы $A \in \mathbb{R}^{m \times n}$ существует разложение:

$$A = U\Sigma V^*,$$

где

- $U \in \mathbb{R}^{m \times m}$ - унитарная матрица левых сингулярных векторов
 - $\Sigma \in \mathbb{R}^{m \times n}$ - диагональная матрица сингулярных чисел
- $$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$$

Сингулярное разложение матрицы

 $A_{m \times n}$

=

 $U_{m \times m}$ σ_1
 σ_2
 σ_3
...
 σ_r $\Sigma_{m \times n}$ $V^*_{n \times n}$

Для любой матрицы $A \in \mathbb{R}^{m \times n}$ существует разложение:

$$A = U\Sigma V^*,$$

где

- $U \in \mathbb{R}^{m \times m}$ - унитарная матрица левых сингулярных векторов
- $\Sigma \in \mathbb{R}^{m \times n}$ - диагональная матрица сингулярных чисел
 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$
- $V \in \mathbb{R}^{n \times n}$ - унитарная матрица правых сингулярных векторов

Сингулярное разложение матрицы

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V^*_{n \times n}$$

Diagram illustrating the SVD decomposition:

- $U_{m \times m}$: Unitary matrix of left singular vectors, represented by vertical lines.
- $\Sigma_{m \times n}$: Diagonal matrix of singular values, represented by a circle containing $\sigma_1, \sigma_2, \sigma_3, \dots, \sigma_r$.
- $V^*_{n \times n}$: Unitary matrix of right singular vectors, represented by horizontal lines.

$$A = \sum_{i=1}^r \sigma_i \cdot u_i \cdot v_i^*$$

$$A_{\text{исср}} = \sum_{i=1}^{r_{\text{исср}}} \tilde{\sigma}_i \tilde{u}_i \cdot \tilde{v}_i^*$$

Для любой матрицы $A \in \mathbb{R}^{m \times n}$ существует разложение:

$$A = U \Sigma V^*,$$

где

- $U \in \mathbb{R}^{m \times m}$ - унитарная матрица левых сингулярных векторов
- $\Sigma \in \mathbb{R}^{m \times n}$ - диагональная матрица сингулярных чисел
 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$
- $V \in \mathbb{R}^{n \times n}$ - унитарная матрица правых сингулярных векторов
- Сингулярные числа единственны. Если все сингулярные числа различны, то разложение единственно с точностью до унитарной диагональной матрицы D :
 $U \Sigma V^* = U D \Sigma (V D)^* = U \Sigma V^*$.

Теорема Экарта-Янга

truncated SVD
усечённое SVD

Наилучшее приближение низкого ранга может быть вычислено с помощью SVD.

💡 Пусть $r < \text{rank}(A)$, $A_r = U_r \Sigma_r V_r^*$. Тогда

$$B = A_r$$

$$\min_{\text{rank}(B)=r} \|A - B\|_2 = \|A - A_r\|_2 = \sigma_{r+1}.$$

То же самое верно для $\|\cdot\|_F$, но $\|A - A_r\|_F = \sqrt{\sigma_{r+1}^2 + \dots + \sigma_{\min(n,m)}^2}$.

Следствие: вычисление наилучшего приближения ранга r эквивалентно установке $\sigma_{r+1} = 0, \dots, \sigma_K = 0$.
Ошибка

$$\min_{A_r} \|A - A_r\|_2 = \sigma_{r+1}, \quad \min_{A_r} \|A - A_r\|_F = \sqrt{\sigma_{r+1}^2 + \dots + \sigma_K^2}$$

вот почему важно смотреть на скорость убывания сингулярных значений.

Пример 1

Найдите SVD следующей матрицы:

$m > n$

$$A = \underset{m \times n}{U} \underset{m \times n}{\Sigma} \underset{n \times n}{V^T}$$

$3 \times 1 \quad 1 \times 1 \quad 1 \times 1$

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = (1) \cdot \begin{pmatrix} 1 \end{pmatrix}$$

$$A = U \Sigma V^T$$

$$U^T U = I$$

$$V^T V = I$$

$$U^T U = I$$

Пример 1

Найдите SVD следующей матрицы:

$$A = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = U \Sigma V^T$$

Уравнение SVD:

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{14}} & \frac{2}{\sqrt{14}} & \frac{3}{\sqrt{14}} \end{pmatrix} \begin{pmatrix} \sqrt{14} & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{14}} & \frac{2}{\sqrt{14}} & \frac{3}{\sqrt{14}} \end{pmatrix}$$

$$U^T U = I$$
$$\left(\frac{1}{\sqrt{14}}, \frac{2}{\sqrt{14}}, \frac{3}{\sqrt{14}} \right) \left(\frac{1}{\sqrt{14}}, \frac{2}{\sqrt{14}}, \frac{3}{\sqrt{14}} \right) = I$$

Пример 1

Найдите SVD следующей матрицы:

$$A = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

Решение

1. Простейшая форма SVD выглядит так:

$$A = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} \\ \frac{2}{\sqrt{14}} \\ \frac{3}{\sqrt{14}} \end{bmatrix} [\sqrt{14}] [1]$$

Пример 1

Найдите SVD следующей матрицы:

$$A = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

Решение

1. Простейшая форма SVD выглядит так:

$$A = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} \\ \frac{2}{\sqrt{14}} \\ \frac{3}{\sqrt{14}} \end{bmatrix} [\sqrt{14}] [1]$$

2. Однако, если вы хотите использовать полную форму с квадратными сингулярными матрицами:

$$A = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{-5}{\sqrt{42}} \\ \frac{2}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{4}{\sqrt{42}} \\ \frac{3}{\sqrt{14}} & \frac{-1}{\sqrt{3}} & \frac{-1}{\sqrt{42}} \end{bmatrix} \begin{bmatrix} \sqrt{14} \\ 0 \\ 0 \end{bmatrix} [1]$$

Пример 1

Найдите SVD следующей матрицы:

$$A = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

3. Вычислим $A^T A$:

$$A^T A = [1 \quad 2 \quad 3] \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = 1^2 + 2^2 + 3^2 = 14.$$

Сингулярные значения σ_i являются квадратными корнями из собственных значений $A^T A$. Поскольку $A^T A$ является 1×1 матрицей со значением 14, сингулярное значение равно $\sigma = \sqrt{14}$.

$$A = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} \\ \frac{2}{\sqrt{14}} \\ \frac{3}{\sqrt{14}} \end{bmatrix} [\sqrt{14}] [1]$$

2. Однако, если вы хотите использовать полную форму с квадратными сингулярными матрицами:

$$A = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{-5}{\sqrt{42}} \\ \frac{2}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{4}{\sqrt{42}} \\ \frac{3}{\sqrt{14}} & \frac{-1}{\sqrt{3}} & \frac{-1}{\sqrt{42}} \end{bmatrix} \begin{bmatrix} \sqrt{14} \\ 0 \\ 0 \end{bmatrix} [1]$$

Пример 1

Найдите SVD следующей матрицы:

$$A = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

3. Вычислим $A^T A$:

$$A^T A = [1 \quad 2 \quad 3] \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = 1^2 + 2^2 + 3^2 = 14.$$

Сингулярные значения σ_i являются квадратными корнями из собственных значений $A^T A$. Поскольку $A^T A$ является 1×1 матрицей со значением 14, сингулярное значение равно $\sigma = \sqrt{14}$.

4. Поскольку V является $n \times n$ ортогональной матрицей (1×1 в этом случае), она может быть $V = [1]$ (или $V = [-1]$). Мы выбираем $V = [1]$.

$$A = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} \\ \frac{2}{\sqrt{14}} \\ \frac{3}{\sqrt{14}} \end{bmatrix} [\sqrt{14}] [1]$$


2. Однако, если вы хотите использовать полную форму с квадратными сингулярными матрицами:

$$A = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{-5}{\sqrt{42}} \\ \frac{2}{\sqrt{14}} & \frac{1}{\sqrt{3}} & \frac{4}{\sqrt{42}} \\ \frac{3}{\sqrt{14}} & \frac{-1}{\sqrt{3}} & \frac{-1}{\sqrt{42}} \end{bmatrix} \begin{bmatrix} \sqrt{14} \\ 0 \\ 0 \end{bmatrix} [1]$$

Пример 2

Решите упражнение Eigenfaces

$$A_{1140 \times 1850} = U_{1140 \times 1140} \sum_{1140 \times 1140} V^T_{1850 \times 1850}$$




$$A_r \leftarrow \sum_{i=1}^r \sigma_i u_i v_i^T$$



Метод главных компонент

Общая идея уменьшения размерности




Метод главных компонент как задача оптимизации



Первая компонента должна быть определена так, чтобы максимизировать дисперсию (вариабельность) проекции.

Предположим, что мы уже нормализовали данные, т.е. $\sum_i a_i = 0$, тогда дисперсия выборки станет суммой всех квадратов проекций точек данных на наш вектор $w_{(1)}$, что приводит к следующей задаче оптимизации:



Метод главных компонент как задача оптимизации



Первая компонента должна быть определена так, чтобы максимизировать дисперсию (вариабельность) проекции.

Предположим, что мы уже нормализовали данные, т.е. $\sum_i a_i = 0$, тогда дисперсия выборки станет суммой всех квадратов проекций точек данных на наш вектор $w_{(1)}$, что приводит к следующей задаче оптимизации:

$$w_{(1)} = \arg \max_{\|w\|=1} \left\{ \sum_i (a_{(i)}^\top \cdot w)^2 \right\}$$

Дисперсия $= E(X^2) - (E(X))^2$

$$\sum (a_{(i)}^\top w)^2$$

Метод главных компонент как задача оптимизации



Первая компонента должна быть определена так, чтобы максимизировать дисперсию (вариабельность) проекции.

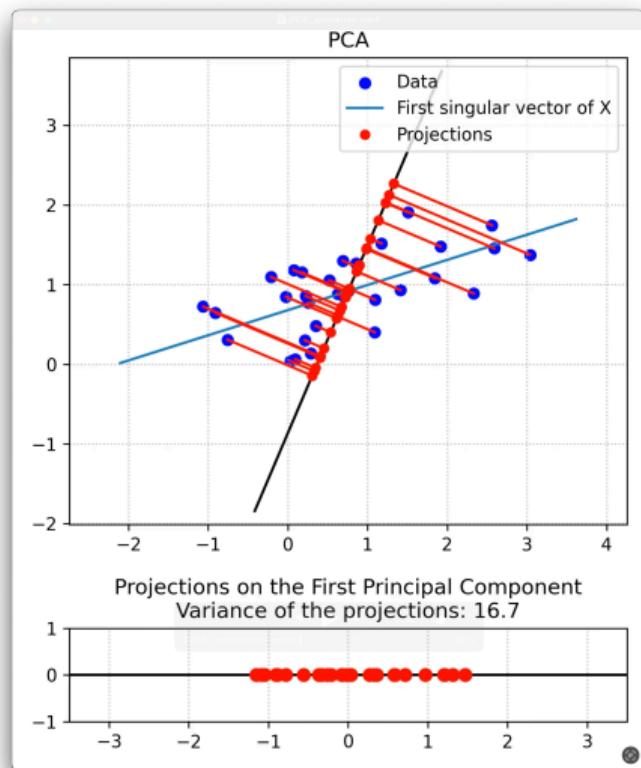
Предположим, что мы уже нормализовали данные, т.е. $\sum_i a_i = 0$, тогда дисперсия выборки станет суммой всех квадратов проекций точек данных на наш вектор $w_{(1)}$, что приводит к следующей задаче оптимизации:

Aw
min $n \times 1$

$$w_{(1)} = \arg \max_{\|w\|=1} \left\{ \sum_i (a_{(i)}^\top \cdot w)^2 \right\}$$

$$w_{(1)} = \arg \max_{\|w\|=1} \{\|Aw\|^2\} = \arg \max_{\|w\|=1} \{w^\top A^\top Aw\}$$

Метод главных компонент как задача оптимизации



Первая компонента должна быть определена так, чтобы максимизировать дисперсию (вариабельность) проекции.

Предположим, что мы уже нормализовали данные, т.е. $\sum_i a_i = 0$, тогда дисперсия выборки станет суммой всех квадратов проекций точек данных на наш вектор $w_{(1)}$, что приводит к следующей задаче оптимизации:


$$w_{(1)} = \arg \max_{\|w\|=1} \left\{ \sum_i (a_{(i)}^\top \cdot w)^2 \right\}$$

$$w_{(1)} = \arg \max_{\|w\|=1} \{\|Aw\|^2\} = \arg \max_{\|w\|=1} \{w^\top A^\top Aw\}$$

так как мы ищем единичный вектор, мы можем переформулировать задачу:

$$w_{(1)} = \arg \max \left\{ \frac{w^\top A^\top Aw}{w^\top w} \right\}$$

Метод главных компонент как задача оптимизации



Первая компонента должна быть определена так, чтобы максимизировать дисперсию (вариабельность) проекции.

Предположим, что мы уже нормализовали данные, т.е. $\sum_i a_i = 0$, тогда дисперсия выборки станет суммой всех квадратов проекций точек данных на наш вектор $w_{(1)}$, что приводит к следующей задаче оптимизации:

$$w_{(1)} = \arg \max_{\|w\|=1} \left\{ \sum_i (a_{(i)}^\top \cdot w)^2 \right\}$$

$$w_{(1)} = \arg \max_{\|w\|=1} \{\|Aw\|^2\} = \arg \max_{\|w\|=1} \{w^\top A^\top Aw\}$$

так как мы ищем единичный вектор, мы можем переформулировать задачу:

$$w_{(1)} = \arg \max \left\{ \frac{w^\top A^\top Aw}{w^\top w} \right\}$$

$\max \frac{x^\top Bx}{x^\top x}$

Известно, что для положительно полуопределенной матрицы $A^\top A$ такой вектор это **собственный вектор** $A^\top A$, соответствующий наибольшему собственному значению.

Вывод метода


Таким образом, мы можем заключить, что следующее
отображение:

$$\Pi_{n \times k} = A_{n \times d} \cdot W_{d \times k}$$

↑
сжатые

$x \in U^T$ сжато

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V^T_{n \times n}$$
$$A^T = V \Sigma U^T$$



Вывод метода

Таким образом, мы можем заключить, что следующее отображение:

$$\underset{n \times k}{\Pi} = \underset{n \times d}{A} \cdot \underset{d \times k}{W}$$

описывает проекцию данных на k главных компонент, где W содержит первые (по величине собственных значений) k собственных векторов $A^\top A$.

Вывод метода

Таким образом, мы можем заключить, что следующее отображение:

$$\underset{n \times k}{\Pi} = \underset{n \times d}{A} \cdot \underset{d \times k}{W}$$

описывает проекцию данных на k главных компонент, где W содержит первые (по величине собственных значений) k собственных векторов $A^T A$.

Теперь мы кратко выведем, как SVD может привести нас к PCA.

Сначала мы запишем SVD нашей матрицы:

$$A = U \Sigma W^T$$

Вывод метода

Таким образом, мы можем заключить, что следующее отображение:

$$\Pi_{n \times k} = A_{n \times d} \cdot W_{d \times k}$$

описывает проекцию данных на k главных компонент, где W содержит первые (по величине собственных значений) k собственных векторов $A^T A$.

Теперь мы кратко выведем, как SVD может привести нас к PCA.

Сначала мы запишем SVD нашей матрицы:

$$A = U \Sigma W^T$$

и транспонируем его:

$$\begin{aligned} A^T &= (U \Sigma W^T)^T \\ &= (W^T)^T \Sigma^T U^T \\ &= W \Sigma^T U^T \\ &= \underline{\underline{W \Sigma U^T}} \end{aligned}$$

Вывод метода

Таким образом, мы можем заключить, что следующее отображение:

$$\Pi_{n \times k} = A_{n \times d} \cdot W_{d \times k}$$

описывает проекцию данных на k главных компонент, где W содержит первые (по величине собственных значений) k собственных векторов $A^T A$.

Теперь мы кратко выведем, как SVD может привести нас к PCA.

Сначала мы запишем SVD нашей матрицы:

$$A = U \Sigma V^T$$

и транспонируем его:

$$\begin{aligned} A^T &= (U \Sigma V^T)^T \\ &= (V^T)^T \Sigma^T U^T \\ &= W \Sigma^T U^T \\ &= W \Sigma U^T \end{aligned}$$

сингулярные
знач.

A

$$\begin{aligned} A^T A &= (W \Sigma U^T)(U \Sigma V^T) \\ &= W \Sigma I \Sigma V^T \\ &= W \Sigma \Sigma V^T \\ &= W \underline{\Sigma^2} V^T \end{aligned}$$

собств
знач. матрицу
 $A^T A$

которая соответствует разложению матрицы $A^T A$, где W - матрица собственных векторов $A^T A$, а Σ^2 содержит собственные значения $A^T A$.

содержит n собственных
векторов матрицы
 $A^T A$

Вывод метода

Таким образом, мы можем заключить, что следующее отображение:

$$\Pi_{n \times k} = A_{n \times d} \cdot W_{d \times k}$$

описывает проекцию данных на k главных компонент, где W содержит первые (по величине собственных значений) k собственных векторов $A^T A$.

Теперь мы кратко выведем, как SVD может привести нас к PCA.

Сначала мы запишем SVD нашей матрицы:

$$A = U \Sigma W^T$$

и транспонируем его:

$$\begin{aligned} A^T &= (U \Sigma W^T)^T \\ &= (W^T)^T \Sigma^T U^T \\ &= W \Sigma^T U^T \\ &= W \Sigma U^T \end{aligned}$$

$$\begin{aligned} A^T A &= (W \Sigma U^T)(U \Sigma V^T) \\ &= W \Sigma I \Sigma W^T \\ &= W \Sigma \Sigma W^T \\ &= W \Sigma^2 W^T \end{aligned}$$

которая соответствует разложению матрицы $A^T A$, где W - матрица собственных векторов $A^T A$, а Σ^2 содержит собственные значения $A^T A$.

В итоге:



$$\begin{aligned} \Pi &= A \cdot W = \\ &= U \Sigma W^T W = U \Sigma \end{aligned}$$

Последняя формула дает нам простой способ вычислить PCA через SVD с любым количеством главных компонент:

$$\Pi_r = U_r \Sigma_r$$


PCA. Упражнение 1

Что могло пойти не так с этим PCA?




PCA. Упражнение 2

Что могло пойти не так с этим PCA?




Projections on the First Principal Component
Variance of the projections: 21.2




PCA. Упражнение 3

PCA




Projections on the First Principal Component
Variance of the projections: 65.7




Что могло пойти не так с этим PCA?


Iris dataset variance



Iris dataset variance




Wine dataset variance




PCA on MNIST

2D PCA of MNIST




t-SNE on MNIST

2D t-SNE of MNIST



UMAP on MNIST

2D UMAP of MNIST



Линейные системы

Матричные разложения и линейные системы

В задаче наименьших квадратов (aka линейной регрессии) мы имеем измерения $X \in \mathbb{R}^{m \times n}$ и $y \in \mathbb{R}^m$ и ищем вектор $\theta \in \mathbb{R}^n$ такой, что $X\theta$ близок к y . Близость определяется как сумма квадратов разностей:

$$\sum_{i=1}^m (x_i^\top \theta - y_i)^2 \quad \|X\theta - y\|_2^2 \rightarrow \min_{\theta \in \mathbb{R}^n} \quad X\theta^* = y$$





Рис. 7: Illustration of linear system aka least squares

Матричные разложения и линейные системы

Moore–Penrose inverse

Если матрица X относительно мала, мы можем записать и вычислить точное решение:

$$\theta^* = (X^\top X)^{-1} X^\top y = X^\dagger y,$$

Матричные разложения и линейные системы

Moore–Penrose inverse

Если матрица X относительно мала, мы можем записать и вычислить точное решение:

$$\theta^* = (X^\top X)^{-1} X^\top y = X^\dagger y,$$

где X^\dagger называется псевдо-обратной матрицей. Однако, этот подход возводит в квадрат число обусловленности задачи, что может быть проблемой для больших и плохо обусловленных задач.

Матричные разложения и линейные системы

Moore–Penrose inverse

Если матрица X относительно мала, мы можем записать и вычислить точное решение:

$$\theta^* = (X^\top X)^{-1} X^\top y = X^\dagger y,$$

где X^\dagger называется псевдо-обратной матрицей. Однако, этот подход возводит в квадрат число обусловленности задачи, что может быть проблемой для больших и плохо обусловленных задач.

QR разложение

Для любой матрицы $X \in \mathbb{R}^{m \times n}$ существует QR разложение:

$$X = Q \cdot R,$$

Матричные разложения и линейные системы

Moore–Penrose inverse

Если матрица X относительно мала, мы можем записать и вычислить точное решение:

$$\theta^* = (X^\top X)^{-1} X^\top y = X^\dagger y,$$

где X^\dagger называется псевдо-обратной матрицей. Однако, этот подход возводит в квадрат число обусловленности задачи, что может быть проблемой для больших и плохо обусловленных задач.

QR разложение

Для любой матрицы $X \in \mathbb{R}^{m \times n}$ существует QR разложение:

$$X = Q \cdot R,$$

где Q – ортогональная матрица (ее столбцы ортогональные единичные векторы) и R – верхняя треугольная матрица. Важно отметить, что поскольку $Q^{-1} = Q^\top$, мы имеем:

$$QR\theta = y \quad \rightarrow \quad R\theta = Q^\top y$$

Теперь процесс нахождения θ состоит из двух шагов:

1. Найдите QR разложение X .

Матричные разложения и линейные системы

Moore–Penrose inverse

Если матрица X относительно мала, мы можем записать и вычислить точное решение:

$$\theta^* = (X^\top X)^{-1} X^\top y = X^\dagger y,$$

где X^\dagger называется псевдо-обратной матрицей. Однако, этот подход возводит в квадрат число обусловленности задачи, что может быть проблемой для больших и плохо обусловленных задач.

QR разложение

Для любой матрицы $X \in \mathbb{R}^{m \times n}$ существует QR разложение:

$$X = Q \cdot R,$$

где Q – ортогональная матрица (ее столбцы ортогональные единичные векторы) и R – верхняя треугольная матрица. Важно отметить, что поскольку $Q^{-1} = Q^\top$, мы имеем:

$$QR\theta = y \quad \rightarrow \quad R\theta = Q^\top y$$

Теперь процесс нахождения θ состоит из двух шагов:

1. Найдите QR разложение X .
2. Решите треугольную систему $R\theta = Q^\top y$, которая треугольная и, следовательно, легко решаемая.

Матричные разложения и линейные системы

Разложение Холецкого

Для любой положительно определенной матрицы $A \in \mathbb{R}^{n \times n}$ существует разложение Холецкого:

$$X^\top X = A = L^\top \cdot L,$$

где L - нижняя треугольная матрица. Мы имеем:

$$L^\top L\theta = y \quad \rightarrow \quad L^\top z_\theta = y$$

Теперь процесс нахождения θ состоит из двух шагов:

1. Найдите разложение Холецкого $X^\top X$.

Обратите внимание, что в этом случае ошибка пропорциональна квадрату числа обусловленности.

Матричные разложения и линейные системы

Разложение Холецкого

Для любой положительно определенной матрицы $A \in \mathbb{R}^{n \times n}$ существует разложение Холецкого:

$$X^\top X = A = L^\top \cdot L,$$

где L - нижняя треугольная матрица. Мы имеем:

$$L^\top L\theta = y \quad \rightarrow \quad L^\top z_\theta = y$$

Теперь процесс нахождения θ состоит из двух шагов:

1. Найдите разложение Холецкого $X^\top X$.
2. Найдите $z_\theta = L\theta$ путем решения треугольной системы $L^\top z_\theta = y$

Обратите внимание, что в этом случае ошибка пропорциональна квадрату числа обусловленности.

Матричные разложения и линейные системы

Разложение Холецкого

Для любой положительно определенной матрицы $A \in \mathbb{R}^{n \times n}$ существует разложение Холецкого:

$$X^\top X = A = L^\top \cdot L,$$

где L - нижняя треугольная матрица. Мы имеем:

$$L^\top L\theta = y \quad \rightarrow \quad L^\top z_\theta = y$$


Теперь процесс нахождения θ состоит из двух шагов:

1. Найдите разложение Холецкого $X^\top X$.
2. Найдите $z_\theta = L\theta$ путем решения треугольной системы $L^\top z_\theta = y$
3. Найдите θ путем решения треугольной системы $L\theta = z_\theta$

Обратите внимание, что в этом случае ошибка пропорциональна квадрату числа обусловленности.


Матричные разложения и линейные системы

Random square linear system




Число обусловленности κ

$$\kappa = 1.0$$



$$\kappa = 100.0$$



$$f \rightarrow \min_{x,y,z}$$

Линейные системы



Матричные разложения и линейные системы

Linear least squares. $\theta_0 = 0.992, \theta_1 = 2.09$

