

# Рандомизированная линейная алгебра

Даня Меркулов

МФТИ. AI360

## Рандомизированная линейная алгебра

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .
3. Вычислить  $A(Br)$  и сравнить полученный вектор с  $Cr$ .

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .
3. Вычислить  $A(Br)$  и сравнить полученный вектор с  $Cr$ .
4. Если  $A(Br) \neq Cr$ , то точно  $AB \neq C$ .



## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .
3. Вычислить  $A(Br)$  и сравнить полученный вектор с  $Cr$ .
4. Если  $A(Br) \neq Cr$ , то точно  $AB \neq C$ .
5. Если  $A(Br) = Cr$ , то с вероятностью **не менее**  $1 - 1/2$  мы угадали правильно. Для снижения вероятности ошибки до  $1/2^k$  повторяем процедуру  $k$  раз с разными случайными векторами.

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .
3. Вычислить  $A(Br)$  и сравнить полученный вектор с  $Cr$ .
4. Если  $A(Br) \neq Cr$ , то точно  $AB \neq C$ .
5. Если  $A(Br) = Cr$ , то с вероятностью **не менее**  $1 - 1/2$  мы угадали правильно. Для снижения вероятности ошибки до  $1/2^k$  повторяем процедуру  $k$  раз с разными случайными векторами.

## Проверка матричного равенства: Алгоритм Фрейвалдса

Пусть нам даны три матрицы  $A, B, C \in \mathbb{R}^{n \times n}$ , и мы хотим проверить, равенство  $AB = C$ . Наивный способ - просто перемножить  $A$  и  $B$  за  $\mathcal{O}(n^3)$  операций и сравнить с  $C$ .

Алгоритм Фрейвалдса показывает, что это можно сделать гораздо быстрее - за  $\mathcal{O}(kn^2)$  операций при вероятности ошибки не более  $1/2^k$ .

**Идея** алгоритма:

1. Сгенерировать случайный вектор  $r \in \mathbb{R}^n$ .
2. Вычислить произведения  $Br$  и  $Cr$ .
3. Вычислить  $A(Br)$  и сравнить полученный вектор с  $Cr$ .
4. Если  $A(Br) \neq Cr$ , то точно  $AB \neq C$ .
5. Если  $A(Br) = Cr$ , то с вероятностью **не менее**  $1 - 1/2$  мы угадали правильно. Для снижения вероятности ошибки до  $1/2^k$  повторяем процедуру  $k$  раз с разными случайными векторами.

**Сложность** каждого шага:  $\mathcal{O}(n^2)$  (домножение на вектор), поэтому общее время  $\mathcal{O}(kn^2)$ .

# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

- Если система совместна, метод сходится к точному решению.

# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

- Если система совместна, метод сходится к точному решению.
- Если система переопределена или шумна, то можно показать сходимость к решению наилучшего приближения.

# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

- Если система совместна, метод сходится к точному решению.
- Если система переопределена или шумна, то можно показать сходимость к решению наилучшего приближения.
- С точки зрения SGD это шаг стохастического градиента для задачи минимизации  $\|Ax - b\|^2$ .

# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

- Если система совместна, метод сходится к точному решению.
- Если система переопределена или шумна, то можно показать сходимость к решению наилучшего приближения.
- С точки зрения SGD это шаг стохастического градиента для задачи минимизации  $\|Ax - b\|^2$ .



# Рандомизированное решение линейной системы

Рассмотрим СЛАУ

$$Ax = b,$$

где  $A \in \mathbb{R}^{m \times n}$ . Метод Качмарца (Kaczmarz) обновляет приближение  $x_k$  путём выборки случайной строки  $i$  (обычно с вероятностью пропорциональной  $\|a_i\|^2$ ):

$$x_{k+1} = x_k - \frac{a_i^T x_k - b_i}{\|a_i\|^2} a_i.$$

- Если система совместна, метод сходится к точному решению.
- Если система переопределена или шумна, то можно показать сходимость к решению наилучшего приближения.
- С точки зрения SGD это шаг стохастического градиента для задачи минимизации  $\|Ax - b\|^2$ .

**Скорость сходимости:**

$$\mathbb{E}[\|x_{k+1} - x^*\|^2] \leq \left(1 - \frac{1}{\kappa_F^2(A)}\right) \mathbb{E}[\|x_k - x^*\|^2],$$

где  $\kappa_F(A) = \frac{\|A\|_F}{\sigma_{\min}(A)}$ .

## Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

# Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

где  $A^{(i_t)}$  -  $i_t$ -й столбец  $A$ , а  $B_{(i_t)}$  -  $i_t$ -я строка  $B$ , а  $p_{i_t}$  - вероятность выбора  $i_t$ -го столбца/строки. Обычно  $p_i$  пропорциональны  $\|A^{(i)}\| \|B_{(i)}\|$  (или другой норме).

# Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

где  $A^{(i_t)}$  -  $i_t$ -й столбец  $A$ , а  $B_{(i_t)}$  -  $i_t$ -я строка  $B$ , а  $p_{i_t}$  - вероятность выбора  $i_t$ -го столбца/строки. Обычно  $p_i$  пропорциональны  $\|A^{(i)}\| \|B_{(i)}\|$  (или другой норме).

**Идея:**

1. По нормам столбцов  $A$  (и строк  $B$ ) выбираем  $k$  столбцов-строк.

# Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

где  $A^{(i_t)}$  -  $i_t$ -й столбец  $A$ , а  $B_{(i_t)}$  -  $i_t$ -я строка  $B$ , а  $p_{i_t}$  - вероятность выбора  $i_t$ -го столбца/строки. Обычно  $p_i$  пропорциональны  $\|A^{(i)}\| \|B_{(i)}\|$  (или другой норме).

**Идея:**

1. По нормам столбцов  $A$  (и строк  $B$ ) выбираем  $k$  столбцов-строк.
2. Усреднённая сумма полученных ранга- $k$  матриц приближает всё произведение.

# Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

где  $A^{(i_t)}$  -  $i_t$ -й столбец  $A$ , а  $B_{(i_t)}$  -  $i_t$ -я строка  $B$ , а  $p_{i_t}$  - вероятность выбора  $i_t$ -го столбца/строки. Обычно  $p_i$  пропорциональны  $\|A^{(i)}\| \|B_{(i)}\|$  (или другой норме).

**Идея:**

1. По нормам столбцов  $A$  (и строк  $B$ ) выбираем  $k$  столбцов-строк.
2. Усреднённая сумма полученных ранга- $k$  матриц приближает всё произведение.

## Рандомизированное матричное умножение

Хотим приблизить произведение  $AB$ , где  $A \in \mathbb{R}^{m \times p}$ ,  $B \in \mathbb{R}^{p \times n}$ . Стоимость точного умножения:  $\mathcal{O}(mnp)$ . Рандомизированный подход даёт приближение:

$$AB \approx \sum_{t=1}^k \frac{1}{k p_{i_t}} A^{(i_t)} B_{(i_t)},$$

где  $A^{(i_t)}$  -  $i_t$ -й столбец  $A$ , а  $B_{(i_t)}$  -  $i_t$ -я строка  $B$ , а  $p_{i_t}$  - вероятность выбора  $i_t$ -го столбца/строки. Обычно  $p_i$  пропорциональны  $\|A^{(i)}\| \|B_{(i)}\|$  (или другой норме).

**Идея:**

1. По нормам столбцов  $A$  (и строк  $B$ ) выбираем  $k$  столбцов-строк.
2. Усреднённая сумма полученных ранга- $k$  матриц приближает всё произведение.

Сложность:  $\mathcal{O}(mnk)$ , если  $k \ll p$ , экономим по сравнению с  $\mathcal{O}(mnp)$ .

# Оценка следа матрицы методом Хатчинсона<sup>1</sup>

Пусть  $X \in \mathbb{R}^{d \times d}$  и  $v \in \mathbb{R}^d$  - случайный вектор такой, что  $\mathbb{E}[vv^T] = I$ . Тогда,

$$\text{Tr}(X) = \mathbb{E}[v^T X v] = \frac{1}{V} \sum_{i=1}^V v_i^T X v_i$$

Интересно, что для оценки следа матрицы иногда можно не знать самой матрицы. Например, в современных моделях машинного обучения можно вычислять произведение гессиана функции на произвольный вектор, не вычисляя сам гессиан с помощью автоматического дифференцирования. 🧠 Пример




Рис. 1: Source

<sup>1</sup>A stochastic estimator of the trace of the influence matrix for Laplacian smoothing splines - M.F. Hutchinson, 1990



# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

## Intrinsic dimension (intdim):

Для симметричной положительно определённой матрицы  $A$  вводится понятие

$$\text{intdim}(A) = \frac{\text{Tr}(A)}{\|A\|_F}.$$

# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

## Intrinsic dimension (intdim):

Для симметричной положительно определённой матрицы  $A$  вводится понятие

$$\text{intdim}(A) = \frac{\text{Tr}(A)}{\|A\|_F}.$$

- Минимальное значение равно 1.

# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

## Intrinsic dimension (intdim):

Для симметричной положительно определённой матрицы  $A$  вводится понятие

$$\text{intdim}(A) = \frac{\text{Tr}(A)}{\|A\|_F}.$$

- Минимальное значение равно 1.
- Максимальное - при всех сингулярных (или собственных) значениях равных, тогда  $\text{intdim}(A)$  может достичь  $\sqrt{\text{rank}(A)}$ .

# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

## Intrinsic dimension (intdim):

Для симметричной положительно определённой матрицы  $A$  вводится понятие

$$\text{intdim}(A) = \frac{\text{Tr}(A)}{\|A\|_F}.$$

- Минимальное значение равно 1.
- Максимальное - при всех сингулярных (или собственных) значениях равных, тогда  $\text{intdim}(A)$  может достичь  $\sqrt{\text{rank}(A)}$ .

# Оценка следа матрицы методом Жирара

## Метод Жирара:

- Предшественник метода Хатчинсона, где вектор  $w$  берём из  $\mathcal{N}(0, I)$  (гауссовский).
- Дисперсия получается немного больше, чем у Хатчинсона (у хатчинсона минимальная дисперсия).

## Intrinsic dimension (intdim):

Для симметричной положительно определённой матрицы  $A$  вводится понятие

$$\text{intdim}(A) = \frac{\text{Tr}(A)}{\|A\|_F}.$$

- Минимальное значение равно 1.
- Максимальное - при всех сингулярных (или собственных) значениях равных, тогда  $\text{intdim}(A)$  может достичь  $\sqrt{\text{rank}(A)}$ .

С помощью этой величины можно оценивать вероятность больших отклонений случайной оценки следа.

# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.

# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.
2. Считаем  $Y = A \cdot G$  и делаем QR-разложение  $Y = QR$ .

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.



# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.
2. Считаем  $Y = A \cdot G$  и делаем QR-разложение  $Y = QR$ .
3. Утверждается, что  $QQ^T A \approx A$  при хорошей выборке и  $k + p$  надёжно покрывают ведущие сингулярные компоненты.

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.

# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.
2. Считаем  $Y = A \cdot G$  и делаем QR-разложение  $Y = QR$ .
3. Утверждается, что  $QQ^T A \approx A$  при хорошей выборке и  $k + p$  надёжно покрывают ведущие сингулярные компоненты.
4. Строим  $B = Q^T A$ , у которого размер  $(k + p) \times n$ .

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.

# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.
2. Считаём  $Y = A \cdot G$  и делаем QR-разложение  $Y = QR$ .
3. Утверждается, что  $QQ^T A \approx A$  при хорошей выборке и  $k + p$  надёжно покрывают ведущие сингулярные компоненты.
4. Строим  $B = Q^T A$ , у которого размер  $(k + p) \times n$ .
5. Вычисляем точное SVD для  $B = \hat{U}\hat{\Sigma}\hat{V}^T$ .

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.

# Рандомизированный SVD

Напомним, что SVD матрицы  $A \in \mathbb{R}^{m \times n}$ :

$$A = U\Sigma V^T.$$

Для больших  $m$  и  $n$  полное вычисление SVD занимает  $\mathcal{O}(\min\{mn^2, m^2n\})$ .

**Рандомизированный подход** (Halko et al., 2011):

1. Выбираем  $G \in \mathbb{R}^{n \times (k+p)}$  со случайными элементами.
2. Считаем  $Y = A \cdot G$  и делаем QR-разложение  $Y = QR$ .
3. Утверждается, что  $QQ^T A \approx A$  при хорошей выборке и  $k + p$  надёжно покрывают ведущие сингулярные компоненты.
4. Строим  $B = Q^T A$ , у которого размер  $(k + p) \times n$ .
5. Вычисляем точное SVD для  $B = \hat{U}\hat{\Sigma}\hat{V}^T$ .
6. Тогда  $U = Q\hat{U}$ , и получаем искомое разложение (приближённое).

Параметр  $p$  - **oversampling**, чтобы уменьшить ошибку.